Sistema de Content-Based Image Retrieval (CBIR) com Contexto Espacial

Disciplina: Recuperação de Informação Multimídia
[Nome do Aluno 1] | Iuri Pedroso
Universidade Estadual do Centro-Oeste (UNICENTRO)
Maio de 2026

1. Introdução

Este relatório documenta a implementação de um sistema de Content-Based Image Retrieval (CBIR) aplicado a imagens de assinaturas do dataset CEDAR. O sistema tem como objetivo recuperar imagens visualmente similares a uma consulta (query), utilizando uma abordagem que pondera a extração clássica de características visuais e a posição espacial (contexto) das regiões de interesse identificadas.

A arquitetura prescinde de métodos de aprendizado profundo (Deep Learning), adequando-se ao escopo de indexação e recuperação clássica por similaridade geométrica e de textura.

2. Dataset e Pré-processamento

Foi selecionado o dataset CEDAR, composto por imagens reais de assinaturas originais e falsificadas. As imagens foram redimensionadas preservando a proporção original e inseridas em um canvas padrão. Em seguida, aplicou-se binarização adaptativa para realçar os traços contra o fundo.

Parâmetro	**Valor**
Total de documentos indexados	25
Total de queries	5
Redimensionamento base	128 × 256 pixels

Figura 1: Amostra dos documentos do dataset CEDAR pré-processados.

3. Propostas de Regiões

Para a identificação dos objetos de interesse, implementou-se o algoritmo de Sliding Window. Três escalas de janelas horizontais varrem a imagem analisando a densidade de pixels pretos. O grande problema dessa varredura é que você acaba com centenas de regiões marcadas em cima da mesma assinatura.

Para limpar essa sobreposição, aplica-se o filtro de Non-Maximum Suppression (NMS). O NMS calcula o IoU (Intersection over Union) entre todas as janelas geradas — se duas janelas se sobrepõem mais de 40% (limiar de 0.4), ele descarta a menor e fica só com a maior, isolando a assinatura principal com precisão.

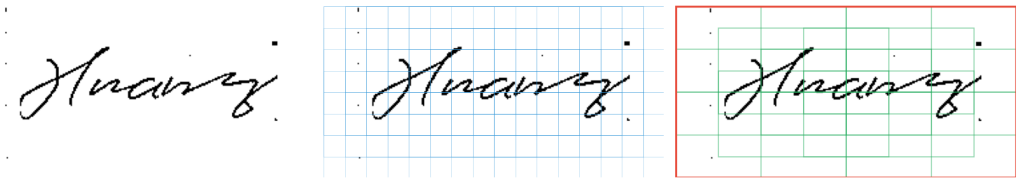

Figura 2: Processo de geração de regiões candidatas e seleção via NMS.

4. Extração de Descritores e Indexação

A representação vetorial de cada região foi construída através da concatenação de três extratores de características:

1. HOG (Histogram of Oriented Gradients): Para captação das distribuições de bordas.

2. Momentos de Hu: Visando capturar invariantes geométricas.

3. LBP (Local Binary Pattern): Para análise de textura.

Os descritores combinados foram submetidos a redução de dimensionalidade (PCA) para 64 componentes e indexados em uma estrutura BallTree (espaço Euclidiano).

5. Ranqueamento

A recuperação pondera a distância no espaço vetorial e a coerência espacial da posição do traço. O cálculo é regido por:

```
Score = (0.7 * Similaridade_Visual) + (0.3 * IoU_Espacial)
```

Essa abordagem garante que traços com formatos semelhantes, mas localizados em posições incompatíveis do canvas, recebam penalidades estruturais.

6. Resultados

Query	Classe	AP	P@1	P@3	P@5
Q25	original	0.611	1.00	0.67	0.60
Q26	falsificada	0.490	0.00	0.67	0.40
Q27	falsificada	0.572	1.00	0.67	0.60
Q28	falsificada	0.561	1.00	0.67	0.60
Q29	falsificada	0.452	0.00	0.33	0.20
—	**MAP**	**0.5371**	—	—	—

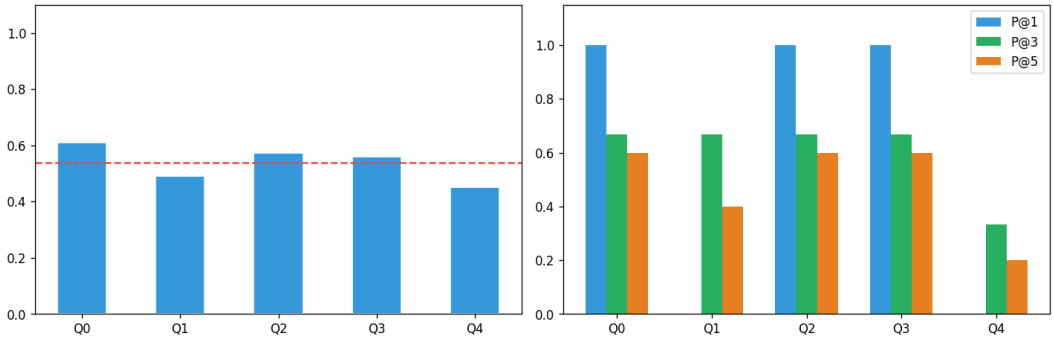

Figura 3: Gráficos de Average Precision e Precision@K.

6.1. Consultas

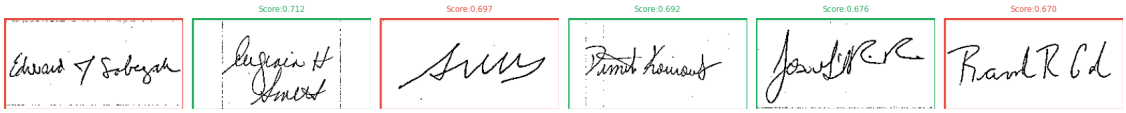

Figura 4: Resultados recuperados para a Q25.

Figura 5: Resultados recuperados para a Q26.

Figura 6: Resultados recuperados para a Q27.

Figura 7: Resultados recuperados para a Q28.

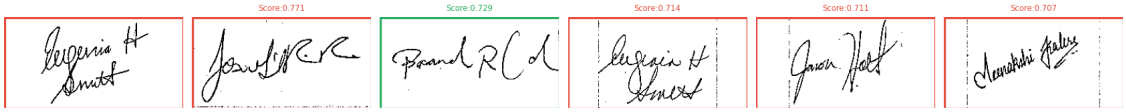

Figura 8: Resultados recuperados para a Q29.

7. Conclusão

O pipeline implementado cumpre as diretrizes estabelecidas. A combinação de algoritmos clássicos de visão computacional demonstrou ser uma ferramenta válida para a estruturação e recuperação de dados puramente baseada no conteúdo e na coerência da posição dos traços.

```
Link do repositório: https://github.com/iuripedroso/TopicosP-Computacao
```