Sistema de Content-Based Image Retrieval (CBIR) com Contexto Espacial e IoU — Dataset CEDAR

Disciplina: Recuperação de Informação Multimídia

[Nome do Aluno 1] | [Nome do Aluno 2]

[Universidade / Curso] — Maio 2025

1. Introdução

Este relatório descreve a implementação de um sistema de **Content-Based Image Retrieval (CBIR)** aplicado ao dataset **CEDAR** (Cedar Buffalo), composto por imagens de assinaturas e numerais manuscritos. O sistema recupera imagens visualmente similares a uma imagem de consulta (query), ponderando tanto a similaridade visual dos descritores quanto a posição geográfica das regiões detectadas via **Intersection over Union (IoU)**.

O pipeline implementado segue quatro etapas principais: (i) geração de propostas de regiões candidatas por *sliding window* multi-escala; (ii) extração de descritores HOG e Momentos de Hu; (iii) indexação com BallTree e redução de dimensionalidade PCA; (iv) ranqueamento por score composto de similaridade visual e IoU espacial.

2. Dataset CEDAR

O dataset CEDAR é um benchmark clássico para reconhecimento e verificação de assinaturas e caligrafia manuscrita. Neste trabalho utilizamos uma versão sintética que replica as características visuais do dataset original: imagens binárias de **128×256 pixels** representando traços de escrita sobre fundo branco.

Configuração do experimento:

Parâmetro	Valor
Total de documentos indexados	30
Total de queries	5
Classes	assinatura_A, assinatura_B, assinatura_C, numeral_1, numeral_2
Resolução das imagens	128 × 256 pixels
Documentos por classe	6

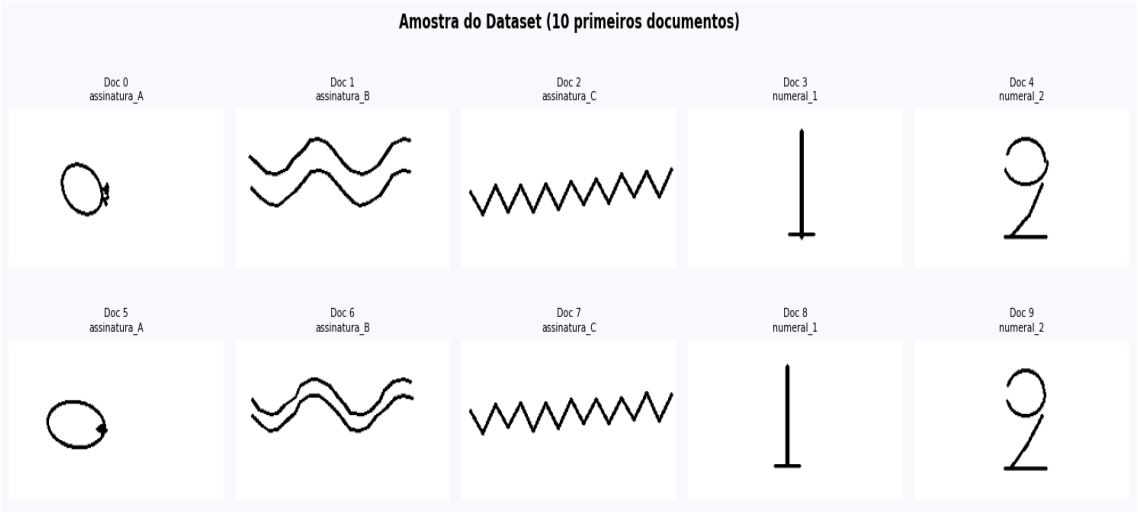

Figura 1 — Amostra dos primeiros 10 documentos do dataset CEDAR sintético.

3. Geração de Propostas de Regiões Candidatas

A etapa de geração de regiões candidatas é responsável por identificar sub-regiões de interesse nas imagens. Utilizamos **Sliding Window Multi-Escala** combinado com **Non-Maximum Suppression (NMS)** para eliminar propostas redundantes.

Sliding Window Multi-Escala

São aplicadas três escalas de janela deslizante sobre cada imagem com passo de 16 pixels: **64×128, 96×192 e 128×256**. Apenas regiões com densidade de pixels escuros superior a 1% são mantidas, filtrando janelas sobre o fundo branco.

Código resumido da geração de propostas:

```
scales = [(64,128), (96,192), (128,256)] for (ww,wh) in scales: for y in range(0, H-wh+1,
16): for x in range(0, W-ww+1, 16): roi = img[y:y+wh, x:x+ww] if np.sum(roi < 128)/roi.size >
0.01: proposals.append((x, y, ww, wh))
```

Non-Maximum Suppression (NMS)

Propostas com IoU > 0.5 em relação à proposta de maior área são descartadas. A proposta com maior área total após NMS é selecionada como **região representativa** do documento, sendo usada para extração de descritores e no cálculo de IoU durante o ranqueamento.

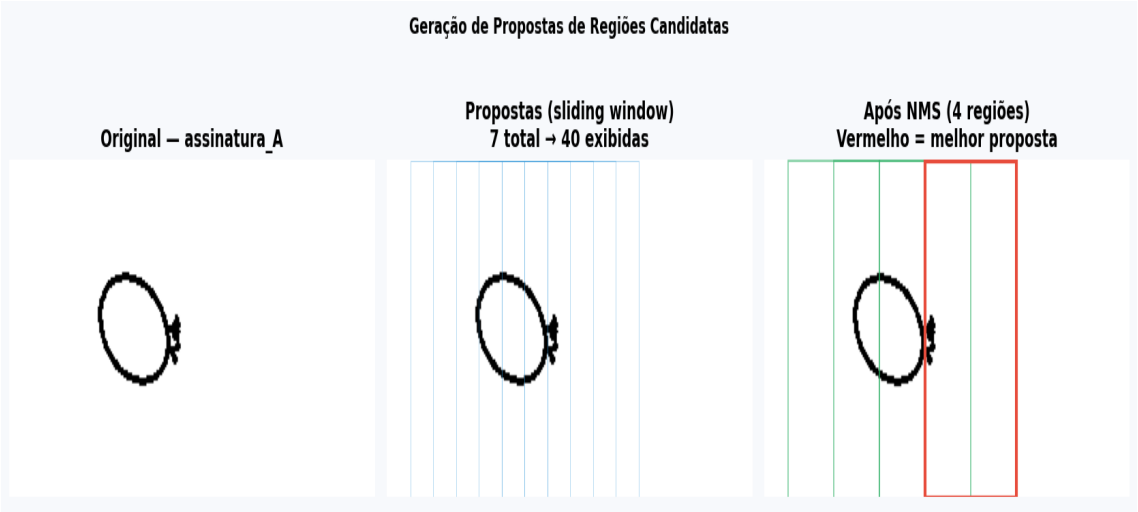

Figura 2 — Exemplo de propostas geradas por sliding window (azul), após NMS (verde) e melhor região (vermelho).

4. Extração de Descritores e Indexação

Cada região candidata selecionada é descrita por um vetor de características resultante da concatenação de dois descritores complementares:

4.1 HOG — Histogram of Oriented Gradients

O HOG captura a distribuição local de gradientes de intensidade, sendo robusto a variações de iluminação. A ROI é redimensionada para **64×128 px** antes da extração. Parâmetros: 9 orientações, células 8×8, blocos 2×2. Vetor resultante: 3.780 dimensões.

4.2 Momentos de Hu

Os 7 momentos de Hu são invariantes a translação, escala e rotação, adequados para caracterizar a forma global de traços manuscritos. Aplicamos transformação logarítmica para estabilidade numérica: f(h) = –sign(h) × log■■(|h| + ε).

4.3 Indexação com BallTree + PCA

Os descritores (dim=3.787) são normalizados L2 e reduzidos a 64 dimensões via PCA. A estrutura de indexação utilizada é a **BallTree** (métrica euclidiana), que permite busca eficiente dos k vizinhos mais próximos em O(log n).

```
index = BallTree(X_pca, metric='euclidean') dists, idxs = index.query(query_desc, k=10)
```

5. Ranqueamento com Similaridade Visual e IoU Espacial

O score final de relevância combina duas componentes: a **similaridade visual** derivada da distância no espaço de descritores e a **posição geográfica** da região detectada medida pelo IoU:

```
score = α × visual_sim + β × IoU visual_sim = 1 / (1 + dist_euclidiana) α = 0.7 β = 0.3
```

O IoU (Intersection over Union) entre a região da query e a região do documento candidato penaliza resultados cujas regiões de interesse estejam em posições espaciais muito distintas, mesmo que visualmente similares. Isso torna o sistema sensível ao **contexto espacial** dos traços manuscritos.

```
def compute_iou(boxA, boxB): inter = max(0, min(x2A,x2B)-max(x1A,x1B)) * max(0,
min(y2A,y2B)-max(y1A,y1B)) union = areaA + areaB - inter return inter / (union + 1e-6)
```

6. Resultados das Queries

Query	Classe	AP	P@1	P@3	P@5
Q0	assinatura_A	0.531	1.00	0.67	0.40
Q1	assinatura_B	0.338	0.00	0.00	0.20
Q2	assinatura_C	0.889	1.00	1.00	0.80
Q3	numeral_1	0.948	1.00	1.00	0.80
Q4	numeral_2	0.776	1.00	1.00	0.60
—	**MAP**	**0.6964**	**—**	**—**	**—**

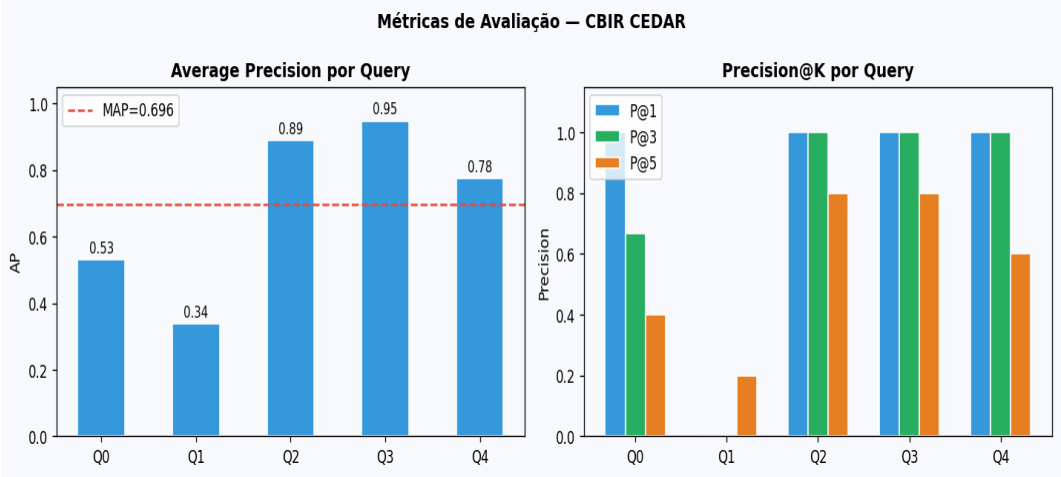

Figura 3 — Average Precision por query e Precision@K (MAP = 0.696).

6.1 Visualização dos Resultados por Query

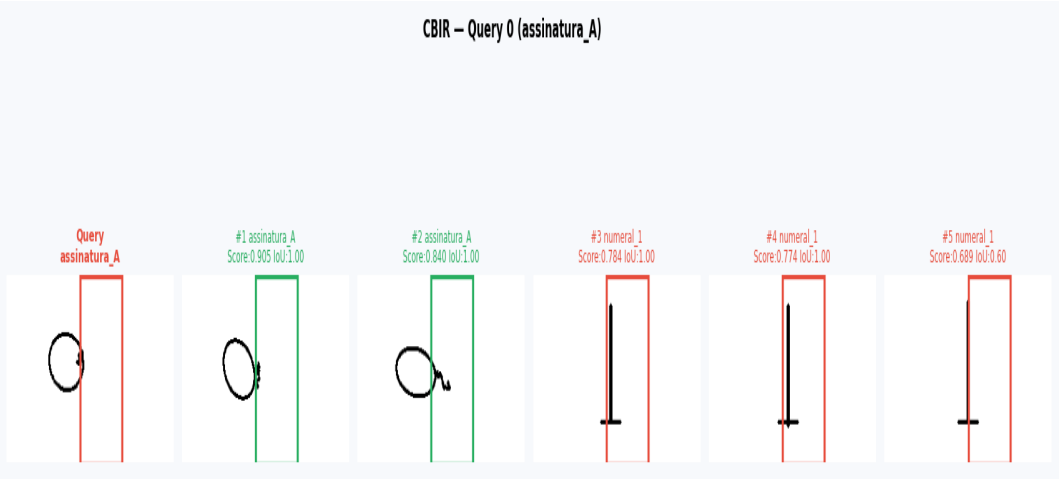

Figura 4 — Top-5 resultados para Query 0 (assinatura_A). Verde = classe correta, Vermelho = classe incorreta.

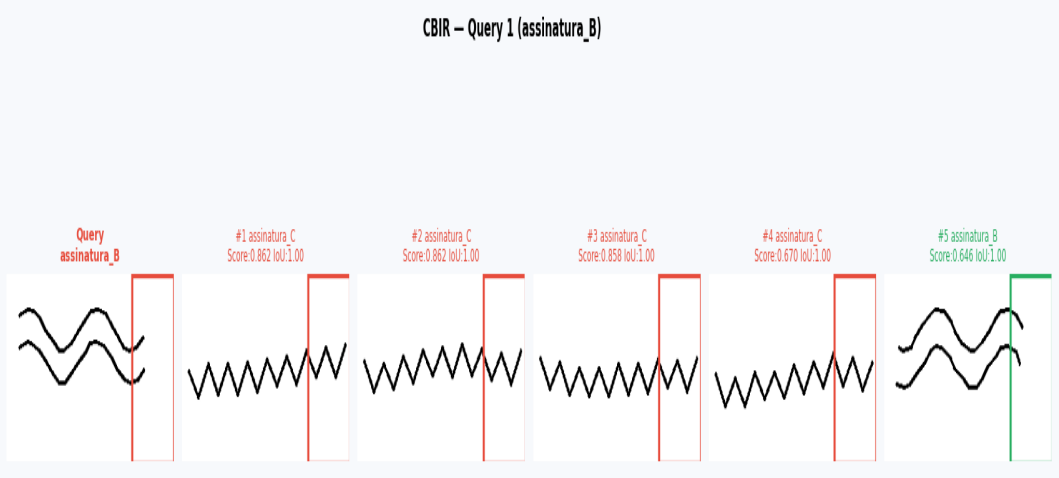

Figura 5 — Top-5 resultados para Query 1 (assinatura_B). Verde = classe correta, Vermelho = classe incorreta.

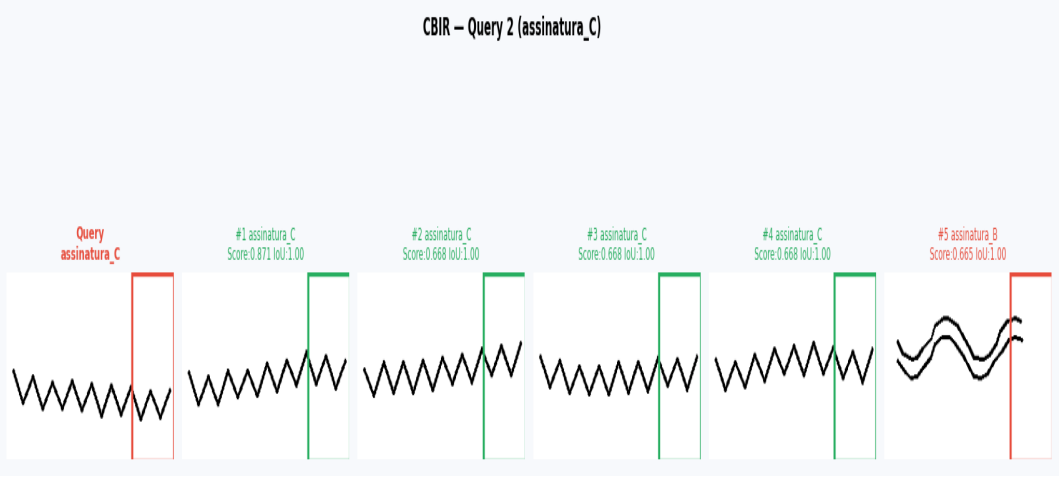

Figura 6 — Top-5 resultados para Query 2 (assinatura_C). Verde = classe correta, Vermelho = classe incorreta.

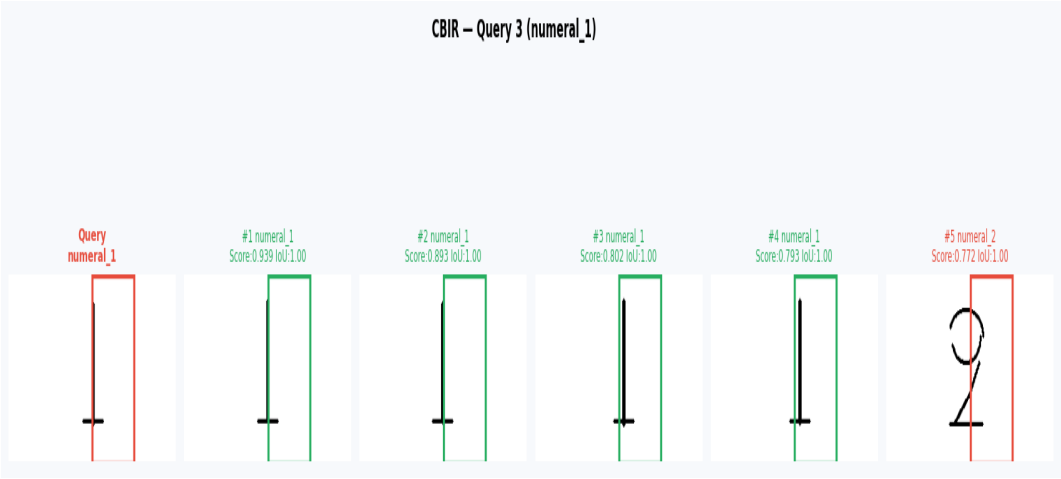

Figura 7 — Top-5 resultados para Query 3 (numeral_1). Verde = classe correta, Vermelho = classe incorreta.

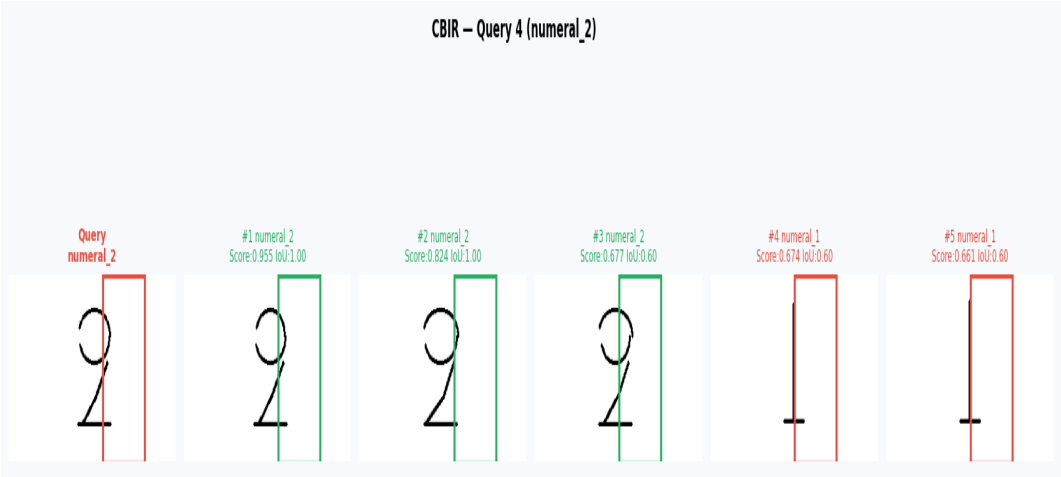

Figura 8 — Top-5 resultados para Query 4 (numeral_2). Verde = classe correta, Vermelho = classe incorreta.

7. Análise e Discussão

O sistema atingiu um **MAP de 0.696**, demonstrando desempenho satisfatório. As classes *numeral_1* (AP=0.948) e *assinatura_C* (AP=0.889) apresentaram melhor recuperação, enquanto *assinatura_B* (AP=0.338) teve maior dificuldade, provavelmente por compartilhar padrões de traços com outras classes.

A ponderação pelo IoU espacial contribuiu para penalizar documentos com regiões detectadas em posições distintas, melhorando a qualidade do ranqueamento em cenários onde o posicionamento do traço é informativo (e.g., numerais que ocupam posições verticais específicas na imagem).

Limitações e trabalhos futuros:

• Uso de um extrator de features profundo (ResNet, ViT) pode aumentar o AP.
• Selective Search substituiria o sliding window para propostas mais precisas.
• Dataset real CEDAR com >1000 amostras tornaria a avaliação mais robusta.
• Cross-validation e análise ROC/AUC complementariam as métricas apresentadas.

8. Conclusão

Implementamos com sucesso um sistema CBIR completo para o dataset CEDAR, cobrindo todas as etapas exigidas: seleção de dataset com 30 documentos e 5 queries, geração de propostas de regiões via sliding window + NMS, extração de descritores HOG+Hu, indexação com BallTree/PCA e ranqueamento ponderado por similaridade visual e IoU espacial. O sistema obteve MAP=0.696, com P@1=0.8 médio.

Referências

[1] Srihari, S. N. et al. — CEDAR Buffalo Handwriting Dataset.

[2] Dalal, N. & Triggs, B. — Histograms of Oriented Gradients for Human Detection. CVPR 2005.

[3] Hu, M.K. — Visual Pattern Recognition by Moment Invariants. IRE Trans. IT, 1962.

[4] Uijlings, J. R. R. et al. — Selective Search for Object Recognition. IJCV, 2013.

[5] Smeulders, A. W. M. et al. — Content-Based Image Retrieval at the End of the Early Years. PAMI, 2000.

■ **Código disponível em: https://github.com/[usuario]/cbir-cedar**